

Bootcamp IGTI: Analista de Machine Learning

Trabalho Prático

Módulo 3

Seleção de Modelos de Aprendizado de Máquina

Objetivos

Exercitar os seguintes conceitos trabalhados no Módulo:

- ✓ Exercitar conceitos sobre medidas de desempenho para regressão.
- ✓ Modelar um problema como uma tarefa de regressão.
- ✓ Avaliar um modelo de regressão.
- ✓ Exercitar conceitos sobre medidas de desempenho para classificação.
- ✓ Modelar um problema como uma tarefa de classificação.
- ✓ Avaliar um modelo de classificação.
- ✓ Exercitar conceitos sobre medidas de desempenho para clusterização.
- ✓ Modelar um problema como uma tarefa de clusterização.
- ✓ Avaliar um modelo de clustering.

Enunciado

Neste trabalho, vamos exercitar conceitos sobre medidas de desempenho vistas em sala de aula a partir da modelagem de 3 problemas diferentes. Para o problema de regressão, usaremos a base diabetes_numeric.csv e uma regressão linear. Para o problema de classificação, usaremos a base bloodtransf.csv e um SVM. Para o problema de clusterização, vamos utilizar a base wine.csv e o algoritmo kmeans.

Atividades

Os alunos deverão desempenhar as seguintes atividades:

- 1. Baixar os arquivos referentes às bases de dados e acessá-las pelo collab.
- 2. Obter informações sobre números de features e instâncias dos datasets.
- 3. Identificar a existência de dados faltantes nos datasets.
- 4. Separar os conjuntos de treino e teste, usando a função **train_test_slipt**, com **test size = 0.35** e **random state = 54**.
- 5. Importar o sklearn para:
- 6. Aplicar à base diabetes_numeric.csv o modelo de regressão linear.
- 7. Avaliar as métricas R2, MAE e MSE.
- 8. Aplicar à base bloodtransf.csv o modelo SVC, com kernel=rbf.
- 9. Avaliar as métricas Acurácia, Precision, Recall, F1 e AUROC
- 10. Aplicar à base wine.csv o modelo kmeans.
- 11. Identificar o número de clusters mais adequado de acordo com o dataset
- 12. Avaliar as métricas Coeficiente de Silhueta, Davies-Bouldin Score e Mutual Information.



